Simulateur Kalman — corrections de l'étape 1

Oct 16, 2026 · @Elias

La course du 2026-10-16 valide le mécanisme mais pas encore la conclusion : au réglage par défaut le filtre ne retire que 46 % du biais de dérive. Le correctif est déjà dans le balayage, et trois autres points méritent d'être réglés avant l'étape 2.

Ce qui est acquis

Quatre résultats tiennent et ne demandent aucune modification. Ils sont à garder tels quels dans la synthèse.

L'information de Fisher est validée. À N = 1000, la covariance prédite reproduit le Monte-Carlo : var J/B 0,02139 contre 0,02126 mesuré (0,6 %), var 5a 180,2 contre 174,7 (3 %), ρ −0,0968 contre −0,0976. Sur trois budgets. C'est la validation de tout le socle statistique — dérivées, convolution, vraisemblance de Poisson — et elle mérite sa propre figure, qu'elle n'a pas aujourd'hui.

5a est rigoureusement insensible à g. Son biais vaut 3,31 / 3,30 / 3,23 / 3,16 mM pour 0 / 5 / 10 / 20 % de dérive. C'est l'hypothèse structurelle de toute l'architecture, et elle est démontrée.

Il n'y a pas de retard de poursuite. Erreur maximale pendant la montée : 3,37 mM pour le Kalman contre 7,68 pour J/B à N = 1000. Le filtre est meilleur *pendant* la transitoire, pas pire. Le compromis précision/bande passante ne mord pas à 10 Hz sur une montée de 2 s.

Le filtre ne coûte rien sans dérive. RMSE 1,19 contre 2,00 pour J/B. Plus : zéro échec dans toutes les conditions, ρ_{12} entre 0,38 et 0,68 donc C et g restent séparables, et P_{22} divisé par deux en 0,59 s.

Ce qui tient à moitié

J/B se dégrade linéairement sous dérive, à **−0,28 mM par point de pourcentage**, exactement comme attendu. Le Kalman, lui, ne retire que 46 % de ce biais au réglage par défaut. Le mécanisme fonctionne ; son réglage, non. C'est l'objet du correctif suivant.

Correctif 1 — Le réglage de σ_w,g

La figure principale utilise le mauvais réglage, et le bon est déjà dans le balayage. C'est la correction la plus rentable : aucun code à écrire, une relance.

À N = 1000, sous rampe, selon σ_w,g :

σ_w,g	biais à 10 %	biais à 20 %	RMSE à 10 %	P_{11}/err^2 à 10 %	récup. après saut
1e−4 (défaut)	−1,45	−2,89	1,55	0,90	23,1 s
3e−4	−1,31	−2,65	1,50	0,97	18,2 s
1e−3	−0,64	−1,45	1,31	1,40	8,7 s
3e−3	**−0,03**	**−0,31**	**1,36**	**1,80**	**1,6 s**

À 3e−3, **89 % du biais de dérive disparaît**, la RMSE s'améliore aussi, et la récupération après un saut passe de 23 s à 1,6 s. Le réglage par défaut interdisait simplement à g de bouger assez vite pour suivre une rampe.

Le chiffre qui le confirme : en fin de course à 1e−4, **ĝ ne suit que 62 % de la dérive** (1,0586 estimé contre 1,0944 vrai).

Ce qu'il faut faire

1. **Relancer la course de référence à σ_w,g = 3e−3** et refaire la figure (a), le panneau (c) et les trois vidéos. La conclusion passe de « corrige à moitié » à « corrige ».
2. **Étendre le balayage vers le haut** — 1e−2, 3e−2 — pour trouver où le sur-desserrage commence à coûter en RMSE sans dérive. Le coût est déjà visible : 1,38 contre 1,19 à dérive nulle. Il y a un optimum et il n'est pas forcément à 3e−3.
3. **Balayer σ_w,g pour les trois budgets**, pas seulement N = 1000. Le réglage optimal dépend probablement du rapport entre le bruit de 5a et la vitesse de dérive, donc du nombre de photons.

Pourquoi ne pas s'arrêter là

Desserrer Q achète la poursuite de la rampe contre de la sensibilité au bruit, et le compromis est visible dans la colonne RMSE à dérive nulle. Le correctif suivant retire ce compromis au lieu de l'arbitrer.

Correctif 2 — Modéliser la dérive comme une rampe

Une marche aléatoire ne peut pas suivre une pente sans retard. C'est un résultat classique d'estimation : un modèle à position seule laisse une erreur de traînage proportionnelle à la pente, quel que soit Q. Desserrer Q réduit le traînage en augmentant la sensibilité au bruit ; ça ne le supprime pas.

La dérive simulée *est* une rampe, et une dérive de gain réelle l'est aussi sur l'échelle de quelques minutes. Donc mets la pente dans l'état :

$$\mathbf{x} = \begin{bmatrix} C \\ g \\ \dot{g} \end{bmatrix}, \qquad g_{k+1} = g_k + \Delta t\,\dot{g}_k, \qquad \dot{g}_{k+1} = \dot{g}_k + w_{\dot{g}}$$

Un modèle à vitesse constante suit une rampe avec **un retard nul en régime**, sans élargir Q sur g. Le bruit de processus ne porte plus que sur l'accélération de la dérive, qui est réellement petite.

Le compromis à mesurer, pas à supposer

Un état de vitesse **dépasse après une discontinuité** : il a appris une pente qui n'existe plus. Le scénario « saut 5 % » est donc le test qui tranche, et il faut le regarder avant d'adopter le modèle.

Trois comparaisons à sortir, sur les mêmes scénarios :

Modèle de g	Rampe	Saut	Aucune dérive
marche aléatoire, σ_w,g = 1e−4	référence actuelle	23,1 s	RMSE 1,19
marche aléatoire, σ_w,g = 3e−3	biais −0,03	1,6 s	RMSE 1,38
(g, ġ)	à mesurer	à mesurer	à mesurer

La question précise : le modèle à vitesse bat-il la marche aléatoire desserrée **sur la rampe sans perdre sur le saut** ? Si oui, il est strictement meilleur. Si le dépassement sur le saut est important, garde la marche aléatoire desserrée — elle est plus simple et déjà suffisante.

Une variante si les deux déçoivent

Un modèle à vitesse avec **rappel vers zéro** sur ġ — un processus d'Ornstein-Uhlenbeck plutôt qu'une marche aléatoire — suit une rampe soutenue tout en oubliant la pente après un saut. Une constante de temps de quelques dizaines de secondes. C'est une ligne de plus et ça prend le meilleur des deux comportements.

Correctif 3 — Le biais de 5a

5a est biaisé de +3,31 mM sans aucune dérive. C'est le problème le plus sérieux, parce que 5a est censé être l'ancre juste du filtre. Une ancre biaisée transfère une partie de son biais sur ĝ, puis sur Ĉ.

N	σ_5a / σ_J/B	biais sans dérive	échecs
300	5,6×	+13,7 mM	25 %
1000	5,8×	+3,31 mM	8,7 %
3000	5,9×	+0,63 mM	1,8 %

Le biais s'effondre avec les photons, donc c'est un biais d'estimateur à faible comptage, pas une erreur de modèle. Mais il est amplifié par l'inversion : les poids valent **w = (−335, +138)**, soit 335 mM par unité de p, sur une p qui ne parcourt que ~0,13 sur toute la titration. Un petit biais de maximum de vraisemblance sur p devient des millimolaires.

L'écart sur les amplitudes, qui est peut-être la cause

Le test de cohérence passe en concentration — C_J/B = C_5a = 20 mM — mais échoue sur les amplitudes :

	5a retrouve	titration donne	écart
p	0,7213	0,6586	**+9,5 %**
q	0,1318	0,1201	**+9,7 %**

Même écart, même signe, stable sur les trois budgets : c'est systématique, pas du bruit. Ce n'est pas fatal puisque la calibration est construite avec le même estimateur et que l'écart s'annule à l'inversion. Mais **5a ne mesure pas les amplitudes que tu crois**, et ça interdit de citer une fraction de population dans un article.

Deux candidats à départager :

- **Une normalisation différente de p** entre le générateur et l'ajustement — p sur deux composantes d'un côté, sur trois de l'autre à cause de la diffusion.
- **Un traitement différent de la diffusion** dans la convolution : incluse dans la somme normalisée d'un côté, additive de l'autre.

Le test qui tranche : générer sans bruit à plusieurs concentrations, et comparer p récupéré contre p injecté sur toute la plage. Si l'écart est un facteur constant, c'est une normalisation ; s'il varie avec la concentration, c'est la diffusion.

Deux pistes pour réduire le biais

Vérifier si q porte quelque chose. σ_C vaut 15,8 mM via p seul, 24,5 via q seul, 13,3 combinés. Le gain de la combinaison est faible, et le poids négatif sur p avec un poids positif sur q mérite d'être compris plutôt que subi. Si q n'apporte presque rien, le retirer simplifie l'estimateur et réduit sa variance.

Corriger le biais de l'estimateur. Un biais de maximum de vraisemblance à faible comptage se corrige par bootstrap sur les tirages, ou par une correction au premier ordre. À N = 1000, retirer 3,3 mM de biais systématique ferait plus pour l'architecture que n'importe quel réglage du filtre.

Correctif 4 — P_{11}/err^2 comme critère de réglage

Le simulateur a trouvé le mode d'échec qu'il cherchait, et il s'avère être aussi l'indicateur de réglage. C'est un résultat à promouvoir, pas un diagnostic à garder dans un coin.

Au mauvais réglage, le filtre est faux et confiant. P_{11}/err^2 tombe à 0,90 sous rampe de 10 %, **0,33 à 20 %**, et 0,15 à N = 3000. Le filtre annonce une précision trois à sept fois meilleure qu'elle ne l'est — exactement le cas qu'on redoutait, puisqu'il a l'air de bien marcher.

Au bon réglage, il remonte à 1,6–1,8 : légèrement sous-confiant, donc sûr.

Le critère qui en découle : **choisir $\sigma_{w,g}$ qui ramène P_{11}/err^2 vers 1 par le haut, sous la dérive la plus forte envisagée.** Il ne demande ni vérité terrain ni connaissance de la dérive — seulement la cohérence interne entre la covariance annoncée et l'erreur réelle, qui est mesurable en simulation et surveillable en expérience.

La figure à ajouter

Une figure dédiée : P_{11}/err^2 contre σ_w,g, une courbe par amplitude de dérive, avec la ligne à 1. Elle dit comment régler le filtre, et c'est la seule sortie de l'étape 1 qui soit directement utilisable par quelqu'un d'autre.

Deux diagnostics à corriger pendant qu'on y est

L'innovation n'est pas blanche. Autocorrélation à −0,21, et surtout une excursion systématique de **−0,18 pendant la montée** contre +0,02 au repos et en relaxation. C'est la signature du modèle de prédiction trop rigide sur C. Ça ne coûte presque rien ici, mais c'est précisément ce que la dépendance de Q en u corrigera à l'étape 2 — donc note-le comme une motivation plutôt que comme un défaut à réparer maintenant.

La covariance d'innovation est surestimée. var_innov_ratio ≈ 0,72 au lieu de 1 : le filtre prédit un écart 40 % plus large que l'écart réel sur le canal ratio. Cohérent avec le sur-lissage, et ça devrait se resserrer avec σ_w,g desserré. À revérifier après la relance.

Ce qui sort

R diagonal : l'avertissement était faux pour ce système

L'écart entre R complet et R diagonal vaut **3,4 % sur la RMSE et 8,3 % sur la calibration**. Négligeable.

La raison est dans les données : ρ mesuré vaut −0,098 à N = 1000 et −0,056 à N = 3000. Les deux lectures sont quasi orthogonales, parce que J/B lit des comptages totaux et 5a des fractions d'amplitude — deux fonctionnelles presque indépendantes des mêmes photons.

Garde R complet dans le code : il ne coûte rien, il est validé, et la corrélation pourrait grandir dans un autre régime. Mais retire la comparaison des figures et du résumé — c'est une ligne de méthodes, pas un résultat.

N = 300 n'est pas un régime de fonctionnement

J/B y atteint 9,8 % d'échecs sous forte dérive, 5a 25 %, et le biais de 5a est de +13,7 mM. Le Kalman tient formellement — zéro échec, RMSE 1,9 — mais il est ancré sur une référence inutilisable.

Garde-le comme borne basse dans le fichier plat, retire-le des figures de conclusion.

Les figures à refaire après la relance

Figure	Pourquoi
(a) biais contre dérive	σ_w,g corrigé ; la conclusion change
(c) RMSE contre budget	idem
(d) ĝ autour du saut	garder, mais centrer sur le réglage retenu
les trois vidéos	régénérer au réglage retenu

Les figures à ajouter

Fisher contre Monte-Carlo — les trois variances et la corrélation, sur les trois budgets. C'est la validation la plus propre du simulateur et elle n'apparaît nulle part.

P_{11}/err² contre σ_w,g — le critère de réglage, décrit au correctif 4.

Critère de sortie vers l'étape 2

Quatre conditions, à vérifier sur la course relancée. Elles sont chiffrées d'avance pour qu'aucune ne se décide après avoir vu les courbes.

1. **Biais du Kalman sous rampe de 10 % : sous 0,3 mM.** Aujourd'hui −1,45 au défaut, −0,03 à 3e−3. C'est la condition principale, celle qui démontre l'architecture.
2. **P_{11}/err² entre 0,8 et 2 sous toutes les dérives.** Aujourd'hui 0,33 au pire. C'est la condition qui garantit que le filtre ne ment pas sur sa propre précision.
3. **RMSE du Kalman sous celle de J/B dans toutes les conditions.** Déjà vrai partout ; à confirmer après le changement de réglage, puisque desserrer Q coûte un peu à dérive nulle.
4. **L'écart sur les amplitudes de 5a expliqué.** Pas nécessairement corrigé — mais sa cause identifiée, parce qu'il touche la validité de tout ce que 5a rapporte.

Ordre de travail

Une relance suffit pour les trois premières conditions : σ_w,g = 3e−3, balayage étendu vers le haut, les trois budgets. Quelques heures de calcul, aucun code nouveau.

Puis le modèle (g, ġ), qui est une vingtaine de lignes dans `kalman.jl` et ne touche ni le générateur ni les lectures. À comparer sur le scénario « saut », qui est là où il peut perdre.

En parallèle, sans calcul lourd : le test d'amplitudes sans bruit sur toute la plage de concentrations, pour trancher entre normalisation et diffusion.

Ce qui ne bloque pas le passage

Le biais de 5a lui-même n'a pas à être corrigé avant l'étape 2, tant que sa cause est connue et que le filtre l'absorbe. La correction par bootstrap est un raffinement, et elle sera plus facile à valider une fois le reste stabilisé.

De même, l'innovation non blanche pendant la montée reste telle quelle : c'est la motivation du Q dépendant de la commande, qui appartient à l'étape 2.